

从象似性与组合性视角看《地书》图形语言与自然语言的异同

——基于经典 NLP 与 Transformer 方法的对比分析

July 15, 2026

目录

① 研究背景与问题

② 数据与方法


③ 结果与发现

④ 结论与讨论

研究背景：徐冰《地书》

《地书》(Earth Book) ——徐冰创作的一套完全由公共标识图形构成的叙事系统。

- 使用图形符号而非文字进行叙事
- 与《天书》形成对偶：从不可读到人人可读
- 挑战“文字是语言唯一载体”的传统认知
- 核心语言学维度：象似性 (Iconicity) 与组合性 (Compositionality)



图

形示例：seg_003470 “微笑”

核心问题：图形语言的象似性与组合性如何体现？与自然语言有何异同？

研究问题 (RQ)

- ① RQ1: 地书图形的象似性分布特征是什么? 与自然语言词汇分布有何异同?
- ② RQ2: 地书图形组合的组合性程度如何? 是否表现出类似自然语言的层级组织?
- ③ RQ3: 经典 NLP 与 Transformer 方法在刻画两类语言异同方面各有何优势?
- ④ RQ4: 篇章关系分布反映了图形叙事的何种认知特征?

数据来源：四组材料

材料 0：标注系统 V1.0

- 纯前端 (Vanilla JS)
- 12,078 个原子图形 (Atom)
- 22 个标注任务配置
- 三级数据模型：Atom / Group / Annotation

材料 1：图形标注数据

- 365 个词标注文件
- 342 个句标注文件
- 7,066 条字面对应词

材料 2：白话文本标注

- 192 个标注文件
- 同一标注框架下的直接可比数据

材料 3：对比语料库

- 四库全书 (古典汉语)
- 世界名著 (现代翻译)
- THUcNews (新闻语料)
- 小说 (约 1,145 万行)
- WikiSentences30k 16Lans

数据预处理流程

JSON 标注文件解析：

```
1 def load_json_files(pattern):
2     files = glob.glob(pattern)
3     records = []
4     for f in files:
5         try:
6             with open(f, 'r', encoding='utf-8') as fh:
7                 data = json.load(fh)
8                 if not data: continue
9                 records.append((os.path.basename(f), data))
10    except (json.JSONDecodeError, UnicodeDecodeError):
11        continue # 跳过异常文件
12    return records
13
```

分析方法：两条技术路径

经典 NLP 方法

- POS-like Category 频次分布统计
- 语义基元 (Semantic Primitives) 编码
- 类形态特征 (Morphological) 提取
- 篇章关系 (Discourse Relations) 分类
- TF-IDF 区分性词汇分析
 - 中文正则分词：
`re.findall(r'[\u4e00-\u9fff]{2,}', t)`
 - `max_features=200 min_df=2`

Transformer 方法

- bert-base-chinese
 - 12 层 Transformer 编码器
 - 隐藏层维度：768
 - 参数量：约 1.02 亿
 - 预训练任务：MLM + NSP


CLS token 隐藏层输出作为句子级语义表示

- 余弦相似度计算语义一致性
- PCA 降维可视化 ($k=2$)
- 采样：两组各 500 条 (计算资源限制)

BERT 嵌入提取代码

```
1 def get_bert_embeddings(texts, tokenizer, model, batch_size=32, max_length=64):
2     embeddings = []
3     model.eval()
4     with torch.no_grad():
5         for i in range(0, len(texts), batch_size):
6             batch = texts[i:i+batch_size]
7             inputs = tokenizer(batch, return_tensors='pt',
8                               padding=True, truncation=True,
9                               max_length=max_length)
10            outputs = model(**inputs)
11            batch_emb = outputs.last_hidden_state[:, 0, :].cpu().numpy()
12            embeddings.append(batch_emb)
13    return np.vstack(embeddings)
```



RQ1: POS 分布——边界标记主导



POS 类别	占比
标点/边界标记	32.3%
动词性 / Action-like	25.7%
名词性 / Entity-like	16.7%
形容词性 / State-like	7.5%
整句/整体表达	8.5%
连接/关系标记	4.3%
虚词/语法标记	1.0%
其他	4.0%


启示：地书语法由空间布局编码，标点/边界标记占比远超自然语言（约 19%）。

RQ1: 语义基元与形态特征



语义基元分布

最频繁基元：运动、情感、人类、有生命



形态特征分布

进行体：2,747 次 现在时：2,356 次

强调：960 次 复数/集合：858 次

白话仅 281 条形态标注

RQ1: 自然语言参照对比

指标	THUcNews	小说
总文档数	5,800	1,145 万行
平均句长 (字)	43.0	55–80
标点密度	0.088	0.10–0.15

自然语言功能词占比约 15–25%

地书功能性元素 (标点 32.3% + 连接 4.3% + 虚词 1.0%) 合计约 **37.6%**


关键发现:

若将标点/边界标记视为图形系统的“功能词等价物”，则地书的功能性元素比例实际上高于自然语言。

差异在于编码模态：

- 自然语言：时间线性
- 地书图形：空间二维

RQ2: 组合性——“宽而浅”假说



指标	数值
总分组数	24,930
覆盖 Atom 数	8,317 / 12,078
覆盖率	68.9%
平均组大小	4.82±4.06
中位组大小	4
Level 1 占比	98.9%
Level 2+ 占比	1.1% (285 个)

宽而浅组合性假设：扁平并置为主，缺乏多层嵌套递归结构。

RQ3: TF-IDF 语义焦点差异

地书图形 Top 10 区分词:

Rank	词汇	Score
1	逗号	0.0149
2	双引号	0.0084
3	冒号	0.0057
4	圆点	0.0047
5	感叹号	0.0041
6	单引号	0.0041
7	三辆车	0.0040
8	省略号	0.0034
9	括号	0.0034
10	动作	0.0028

白话文本 Top 10 区分词:

Rank	词汇
1	完成态
2	蚊子
3	男生说
4	他们
5	所有格
6	调查
7	我们
8	助词
9	女生说
10	感到


启示: 图形释义依赖空间关系, 文本释义
依赖语法与角色。

RQ3: BERT 语义嵌入分析

Metric	Mean	Std	Median
地书组内	0.7697	0.1036	0.7819
白话组内	0.7860	0.1044	0.7990
跨组相似	0.7629	0.0948	0.7710


发现:

- 地书释义具有一致性 (象似性约束)
- 白话更标准化 (社区规范约束)
- 跨组差异约 0.02–0.03
- BERT 深层语义部分平滑了两组差异



PCA 可视化: POS 形成连续语义梯度

RQ3: BERT 相似度分布




三列分别为：

- 左：地书组内相似度分布
- 中：白话组内相似度分布
- 右：跨组相似度分布

三组均值均在 0.76–0.79 之间，分布形态接近正态。

启示：BERT 训练数据中包含大量描述性文本，使得视觉描述与概念描述在向量空间中部分重叠。

RQ4: 篇章关系——强时序叙事



篇章关系	占比
------	----

时间先后	43.7%
------	-------

因果	17.9%
----	-------

并列递进	15.4%
------	-------

转折	10.2%
----	-------

解释说明	4.6%
------	------

条件	1.4%
----	------

无明显关系	5.8%
-------	------

无法判断	0.9%
------	------

顺序象似性 (Givón, 1985): 事件物理先后顺序直接映射为图形空间先后顺序。

多维度发现汇总

象似性三维结构

- ① 图形-概念象似性
BERT 组内 0.770
- ② 序列-事件象似性
时间先后 43.7%
- ③ 组合-结构象似性
组大小 4.82

空间拓扑标记

- 标点/边界标记 32.3%
- 功能等价物 > 自然语言
- 二维空间编码替代时间线性编码
- 语法内嵌于视觉形式

方法互补性

- 经典 NLP: 宏观分布规律
- BERT: 深层语义一致性
- TF-IDF: 词汇焦点差异
- PCA: 语义空间结构

主要结论

- ① **象似性**：地书 POS 分布高度集中（边界标记 32.3%），象似性编码直接导致词性-视觉形态强绑定。BERT 组内相似度 0.770 验证了语义约束强度。
- ② **组合性**：呈现“宽而浅”结构——平均组大小 4.82 ± 4.06 ，Level 1 占 98.9%，深层嵌套仅 1.1%。与自然语言的递归句法形成对比。
- ③ **语法编码**：空间拓扑标记（37.6%）替代自然语言功能词（15–25%）。语法关系由视觉布局 and 空间顺序编码，不存在形式与内容的分层。
- ④ **叙事特征**：以动态事件为核心（运动/情感/人类基元主导），篇章关系以时序为主轴（43.7%），缺乏条件/让步等复杂逻辑。
- ⑤ **方法互补**：经典 NLP 揭示宏观结构规律（分布、TF-IDF、分组统计），BERT 量化语义一致性（768 维向量空间中的相似度）。

理论对话

支持的理论

- Givón (1985) 顺序象似性：时间先后 43.7%
- Jackendoff (2002) 平行架构：语义驱动组合
- 认知语法组块化：组大小 $4.82 \approx$ Miller 4 组块
- 沈家煊名动包含：POS 连续梯度

“宽而浅组合性假说”：地书具有中等程度组合性——可线性组合形成内部结构单元，但缺乏递归嵌套机制。

挑战的观点

- Chomsky (1957) 递归性：地书缺乏深层递归
- 语言功能词必要性：地书无独立功能词
- 形式与内容分层：地书语法内嵌于视觉

局限与未来工作

局限：

- 量表数据缺失：标注者未填写 1-7 分量表（iconicity、compositionality），无法直接对比主观评分
- BERT 采样限制：两组各 500 条，可能存在长尾偏差
- 缺乏跨模态对比：未直接处理图形图像（仅分析标注文本）
- 标注一致性未评估：未计算 Kappa 系数

未来方向：

- 引入 CLIP 等多模态模型，直接对比图形图像与文本嵌入
- 更大规模标注一致性实验
- 与 emoji、Blissymbolics 等图形符号系统跨系统比较
- 基于 LLM 的地书自动翻译与生成验证